

ProspectusInsight Agent 项目报告

项目名称：ProspectusInsight Agent：招股说明书智能解读与公司画像生成助手

项目类型：AI 智能体设计开发及应用课程大作业

适用范围：公开招股说明书资料整理、学习辅助和初步分析

重要边界：本项目不构成投资建议，不输出买卖建议、目标价、投资评级或收益预测；所有关键事实、财务数据和风险判断均需人工复核。

一、项目概述

ProspectusInsight Agent 是一个面向招股说明书阅读场景的智能体应用。用户上传招股说明书 PDF 后，系统自动完成 PDF 文本解析、重点内容筛选、结构化信息抽取、Markdown/CSV/JSON 报告生成，并可选将摘要推送到飞书机器人。

本项目聚焦“公开披露文件的结构化整理”这一明确任务。招股说明书通常篇幅长、章节多、信息密度高，人工阅读时需要在公司概况、业务、行业、财务、风险因素、募集资金用途等章节之间反复查找。该智能体通过工作流和大模型协同，把长文档转换为便于学习、讨论和复核的结构化公司画像。

二、服务对象

本智能体主要服务以下对象：

服务对象	使用场景
金融专业学生	阅读上市招股说明书，训练公司分析、行业分析和风险识别能力
行业研究实习生	快速梳理公司业务、财务和风险信息，形成初步资料包
投行、咨询、数据分析初学者	学习公开披露文件的信息抽取方法和报告组织方式

本项目不面向投资决策用户，不提供任何交易建议，只作为公开资料整理和课程学习辅助工具。

三、具体问题与痛点

当前场景中的主要低效环节包括：

- 1. 招股说明书页数多、信息密度高，初学者第一次阅读时很难快速抓住重点。
- 2. 公司简介、发展历程、核心高管、股权架构、行业格局、主营业务、财务指标和风险提示分散在不同章节。
- 3. 人工整理 Markdown 报告、CSV 摘要和飞书通知文本耗时较长，且容易遗漏字段。
- 4. 不同小组成员对同一份材料的整理口径可能不一致，后续讨论缺少统一结构。
- 5. 直接让大模型自由回答容易出现补充外部信息、编造细节或给出不恰当投资判断的风险。

因此，本项目的设计重点不是“替代专业判断”，而是把重复性的阅读、提取、整理、格式化和协同通知流程自动化，同时保留“未识别”和“人工复核”机制。

四、工作流程

（一）输入内容

用户需要输入：

输入项	是否必填	说明
招股说明书 PDF	必填	用户上传的公开招股说明书文件，当前版本主要支持可提取文本的 PDF
公司名称	可选	用户可手动填写；留空时由模型从 PDF 文本中识别
是否推送飞书	可选	勾选后调用飞书机器人 Webhook 推送摘要
`.env` 配置	运行时需要	包括 `LLM_API_KEY`、

		`LLM_BASE_URL`、 `LLM_MODEL`、 `FEISHU_WEBHOOK_URL` 等
--	--	---

系统不会联网搜索公司资料，也不会用外部资料补齐 PDF 中没有披露的信息。输入为英文、繁体中文或中英混合时，面向用户的主要输出仍使用简体中文。

ProspectusInsight Agent

招股说明书智能解读与公司画像生成助手

项目边界：本工具只做公开资料整理和初步分析，不构成投资建议；不生成买入、卖出、目标价、投资评级或收益预测；AI 输出需人工复核。

上传一份招股说明书 PDF

英矽智能招股说明书.pdf

27.5MB

+

公司名称（可选，留空则由 AI 从文本中识别）

☒ 解读完成后推送飞书机器人

开始解读

图 1 项目首页输入示例

(二) 输出结果

智能体最终生成以下结果：

输出结果	文件或位置	说明
页面解读结果	Streamlit 页面	按标签页展示公司简介、行业分析、业务分析、财务分析、风险与募资、证据与复核
Markdown 报告	`code/outputs/prospectus_report.md`	面向阅读和提交的完整解读报告
JSON 结构化结果	`code/outputs/prospectus_analysis.json`	稳定字段的结构化抽取结果，便于二次处理
CSV 摘要表	`code/outputs/prospectus_summary.csv`	公司名称、行业、业务模式、收入来源、财务、风险、募资用途

		等摘要字段
飞书摘要文本	`code/outputs/feishu_message.txt`	适合群通知的短摘要
飞书机器人推送	飞书群	在配置 Webhook 后可推送摘要和报告路径

报告至少覆盖以下模块：

- 1. 公司简介：基本信息、发展历程、核心高管、股权架构、上市信息。
- 2. 行业分析：行业发展现状、市场驱动因素、竞争格局、公司行业地位。
- 3. 业务分析：业务模式、核心产品或服务、收入拆分、客户与供应商、商业化进展。
- 4. 财务分析：主要财务指标、收入利润现金流变化、资产负债、关键变化、财务不确定性。
- 5. 风险提示：主要风险、风险影响、原文依据。
- 6. 募资用途：募资项目、金额或比例、资金用途、未识别项目。
- 7. 尽调问题：公司治理、业务产品、财务经营、风险核验、募资用途核验。
- 8. 证据片段和不确定性说明：标注模型依据和需要人工复核的内容。



ProspectusInsight 招股说明书智能解读报告

本报告仅基于用户上传的公开招股说明书文本生成，用于学习辅助和初步资料整理，不构成投资建议。关键数据、口径和结论均需人工复核。

1. 分析对象与资料来源

- 公司名称：英矽智能 InSilico Medicine Cayman TopCo
- 文件类型：招股说明书
- 拟上市市场：未识别
- 资料来源：/tmp/tmpwmgov3sy.pdf
- 生成说明：AI 输出可能存在识别误差，所有重要信息应回到原文核验。

2. 公司简介

2.1 基本信息

- 开曼群岛注册成立的有限公司，股份代号3696
- 核心业务为AI驱动的药物发现与管线开发

图 3 Markdown 报告示例

```
{
  "company_name": "英矽智能 InSilico Medicine Cayman TopCo",
  "filing_type": "招股说明书",
  "listing_market": "未识别",
  "industry": "AI驱动的药物发现与开发",
  "company_profile": "一家专注于生成式AI赋能药物发现与开发的生物科技公司",
  "business_model": "采取数据驱动的决策模式，对符合长期策略的项目自主开发，",
  "main_products_or_services": [
    "Pharma.AI平台",
    "管线候选药物：ISM3091、ISM5043",
    "软件解决方案订阅服务及非医药领域AI发现合作"
  ],
  "revenue_sources": "药物发现及管线开发（主要）、软件解决方案订阅费、与非医药",
  "key_financials": "2022-2024年及2025年上半年收入分别为30.1百万美元、51.1",
  "customers_and_suppliers": [
    "主要客户均为药企/生物科技公司等独立第三方",
    "五大客户贡献总收入86.2%-94.4%，最大客户占比56.6%-76.3%",
    "客户E为一家领先的国际制药及诊断公司",
    "业绩记录期内五大客户均非公司供应商"
  ],
  "risk_factors": "持续净亏损及负经营现金流风险；客户高度集中风险；美国及中",
  "company_overview": {
    "basic_info": [
      "开曼群岛注册成立的有限公司，股份代号3696",
      "核心业务为AI驱动的药物发现与管线开发",
      "拥有专有生成式AI平台Pharma.AI",
      "截至最后实际可行日期尚无商业化产品"
    ],
    "development_history": [
      "2016年InSilico LLC在俄罗斯注册成立",
      "2021年完成C轮融资及股份赎回",
      "2022年10月出售InSilico LLC，将AI开发业务重心转移至中东",
      "2023-2024年先后与Exelixis、Stemline达成管线药物对外授权协议"
    ]
  }
}
```

图 4 JSON 输出

company_name,industry,business_model,revenue_sources,key_financials,risk_factors,use_of_proceeds,uncertainty_notes
英矽智能 InSilico Medicine Cayman TopCo, AI药物发现及开发(AIDD)正成为制药产业重要趋势; 生成式AI在药物开发早期与后期阶段应用

图 5 CSV 概要表

 招股说明书智能体 机器人 | 推送招股说明书解读

ProspectusInsight 招股书解读摘要

公司名称: 英矽智能 InSilico Medicine Cayman TopCo

所属行业: AI药物发现及开发(AIDD)正成为制药产业重要趋势; 生成式AI在药物开发早期与后期阶段应用日益广泛; 全球AIDD市场规模预计从2023年119亿美元增长至2032年746亿美元

核心业务: 预设自主开发符合长期策略且具备技术优势的项目; 对产生足够数据验证科学原理与市场潜力的项目对外授权; 在外部合作伙伴缺乏资源或项目复杂时选择共同开发

主要风险: 过往及未来可能继续产生净亏损及负经营现金流; 收入高度集中于少数主要客户, 流失任一客户将造成重大不利影响; 美国IRC第7874条及中国实际管理机构规则可能导致税务居民身份不确定性

尽调问题数量: 15

报告保存路径: [outputs/prospectus_report.md](#)

提示: 本摘要仅用于公开资料整理, 不构成投资建议。

图 6 飞书机器人摘要截图

(三) 处理步骤

智能体工作流如下:

1. 用户在 Streamlit 页面上传招股说明书 PDF。pdf_parser.py 使用 PyMuPDF 提取 PDF 文本, 并保留页码信息。
2. pipeline.py 对长文本做重点内容筛选, 优先保留公司概况、业务、财务、风险、募集资金用途等相关段落。
3. llm_client.py 读取 Prompt 和 .env 配置, 调用 OpenAI-compatible API。
4. 大模型按固定 JSON schema 抽取公司、行业、业务、财务、风险、募资用途和尽调问题。
5. ensure_schema 对缺失字段进行补齐, 统一填入“未识别”, 避免输出结构不稳定。
6. report_generator.py 生成 Markdown 报告。
7. pipeline.py 保存 JSON、CSV、Markdown 和飞书摘要。
8. feishu_bot.py 在用户请求且 Webhook 配置完整时推送飞书消息。
9. 用户根据报告中的证据片段和不确定性说明回到原始招股说明书复核。




图 7 工作流示意图

五、模型任务

大模型主要承担理解、抽取、归纳和生成类任务：

模型任务	说明
文档理解	理解招股说明书中的公司、行业、业务、财务、风险和募资相关内容
信息分类	将原文信息归入公司简介、行业分析、业务分析、财务分析、风险提示等模块
结构化抽取	按固定 JSON 字段输出公司名称、上市市场、核心产品、收入拆分、主要财务指标等
摘要生成	将长段落压缩为适合报告展示的简体中文摘要
尽调问题生成	基于披露内容生成后续核验问题，帮助用户发现需要进一步确认的事项
不确定性说明	对缺失、模糊或证据不足的信息进行说明

模型必须遵守以下约束：

- 1. 只基于用户上传 PDF 的可提取文本回答。
- 2. 不联网搜索，不补充外部事实。
- 3. 未披露、未识别或证据不足的信息写“未识别”。
- 4. 输出使用简体中文。
- 5. 不生成投资建议、目标价、评级、收益预测或交易结论。
- 6. 关键数据和风险结论保留人工复核提示。

六、工具任务

workflows、代码、CLI 和飞书承担确定性任务：

工具任务	对应模块
------	------

PDF 解析	`agent/pdf_parser.py` 使用 PyMuPDF 提取文本
文本筛选	`agent/pipeline.py` 根据关键词和长度限制保留重点段落
API 调用	`agent/llm_client.py` 读取 `.env` 并调用 OpenAI-compatible API
Schema 补齐	`agent/pipeline.py` 对缺失字段填“未识别”
Markdown 生成	`agent/report_generator.py` 生成完整报告
CSV/JSON 保存	`agent/pipeline.py` 保存结构化输出
飞书消息构造与推送	`agent/feishu_bot.py` 生成短摘要并推送 Webhook
Streamlit 交互界面	`agent/app.py` 提供上传、运行、展示和下载入口
CLI 运行和测试	`scripts/run_pipeline.py`、`scripts/test_api.py`、 `scripts/test_feishu.py`
静态展示网站	`code/index.html`、`code/pages/`、`code/css/`、 `code/js/`

工具部分负责“可重复、可验证、格式稳定”的流程，大模型负责“理解、总结、归类、生成”的语言任务，两者结合形成完整智能体。

七、异常情况处理

异常情况	处理方式
用户未上传 PDF	Streamlit 页面提示“请先上传招股说明书 PDF”
PDF 为空	提示上传有效 PDF
PDF 为扫描版或无法提取足够文本	提示可能需要先 OCR 后再上传
缺少 `LLM_API_KEY`	提示配置 `.env`，不继续调用模型

LLM 调用失败	返回可读错误信息，避免页面崩溃
模型输出缺字段	自动按 schema 补齐，缺失内容写“未识别”
模型输出非 JSON	返回模型格式异常提示，后续可通过 Prompt 继续收紧
飞书 Webhook 未配置	跳过推送，保留本地摘要文件，不影响报告生成
PDF 中没有披露某项信息	不编造，报告中标注“未识别”或写入不确定性说明
结果可能不准确	报告首部和页面提示用户进行人工复核

八、项目实施

（一）项目结构

```
``text
code/
├─ agent/
│   ├── app.py           # Streamlit 应用入口
│   ├── pipeline.py      # 主流程：解析、筛选、抽取、输出、飞书
│   ├── pdf_parser.py    # PDF 文本提取
│   ├── llm_client.py    # OpenAI-compatible API 调用
│   ├── report_generator.py # Markdown 报告生成
│   └── feishu_bot.py    # 飞书消息构造与推送
├─ prompts/
│   └── extraction_prompt.md # 结构化抽取 Prompt
├─ scripts/
│   ├── run_pipeline.py  # CLI 运行 pipeline
│   ├── test_api.py      # API 连通性测试
│   └── test_feishu.py   # 飞书机器人测试
├─ tests/
│   ├── test_detailed_schema.py
│   ├── test_detailed_report_generator.py
│   └── test_feishu_message.py
├─ docs/
│   └── final_project_documentation.md
└─ outputs/
    ├── prospectus_analysis.json
    ├── prospectus_report.md
    ├── prospectus_summary.csv
    └── feishu_message.txt
```

```
```
```

## (二) 运行与验证方式

进入 code 目录后，推荐使用 uv 安装依赖并运行：

```
```bash
uv venv
uv pip install -r requirements.txt
```
```

配置 .env：

```
```text
LLM_API_KEY=你的 API Key
LLM_BASE_URL=OpenAI-compatible Base URL，可留空使用默认 OpenAI 地址
LLM_MODEL=模型名称
FEISHU_WEBHOOK_URL=飞书自定义机器人 Webhook，可选
```
```

运行 Streamlit：

```
```bash
uv run python -m streamlit run agent/app.py
```
```

运行 CLI pipeline：

```
```bash
uv run python scripts/run_pipeline.py --pdf data/example_prospectus.pdf --company "示例公司"
```
```

使用根目录样例 PDF 调试：

```
```bash
uv run python scripts/run_pipeline.py --pdf ../英矽智能招股说明书.pdf --company "英矽智能"
```
```

可选测试命令：

```
```bash
uv run python scripts/test_api.py
uv run python scripts/test_feishu.py
uv run python -m unittest tests.test_detailed_schema
tests.test_detailed_report_generator tests.test_feishu_message -v
```
```

说明：

- test\_api.py 需要有效 LLM\_API\_KEY。
- test\_feishu.py 需要有效 FEISHU\_WEBHOOK\_URL，未配置时应友好提示。

- 静态网页可直接打开 `code/index.html` 检查，也可用本地静态服务器预览。

## 九、项目总结与反思

### 1. AI 自动化的价值

AI Agent 适合处理“长文档阅读后形成结构化材料”的重复性工作。招股说明书本身信息公开，但篇幅长、章节多、专业性强。通过 PDF 解析、LLM 抽取、报告生成和飞书通知，系统可以帮助学生更快建立公司画像，降低第一次阅读公开披露文件的门槛。

### 2. 大模型适合做什么

大模型适合完成理解、归纳、分类、摘要和问题生成。例如，它可以把业务模式、风险因素、募资用途等分散内容整理成统一结构，也可以基于披露信息生成后续尽调问题。这些任务依赖语言理解和上下文归纳，适合由模型完成。

### 3. 工具和代码为什么仍然重要

如果只使用聊天式大模型，输出格式容易不稳定，也难以保存、复用和协同。项目中使用 Python pipeline、固定 schema、Markdown/CSV/JSON 输出和飞书推送，把模型能力嵌入可重复的工作流中。工具负责流程控制和格式稳定，模型负责语义理解，两者结合才更像一个完整智能体。

### 4. 幻觉与误读风险

招股说明书分析涉及财务、法律、行业和监管表达。模型可能因为 PDF 解析错误、表格抽取不完整、上下文截断或 Prompt 理解偏差而遗漏信息或误读含义。因此项目必须限制模型只基于上传文本回答，并在缺失信息时写“未识别”。这比“让结果看起来完整”更重要。

### 5. 为什么保留人工复核

公司财务指标、股权结构、募集资金用途和风险因素都可能影响读者对企业的理解。AI 输出只能作为初步资料整理，不能替代原文核验和专业判断。因此报告首部、页面提示和结果字段中都保留人工复核说明，要求用户回到原始招股说明书确认关键内容。

## 6. 为什么不做投资建议

本项目是课程学习和公开资料整理工具，不具备完整尽职调查、估值建模、审计、法律核验和投资决策能力。为了避免误导用户，系统不输出买入、卖出、持有、目标价、收益预测或投资评级，只输出结构化信息、风险提示和尽调问题。

## 7. 开发过程中的收获

本项目体现了 AI 智能体开发的几个关键点：

- 真实场景要先明确边界，否则很容易从“资料整理”扩展成不可靠的“投资判断”。
- Prompt 需要和代码 schema 配合，才能得到稳定输出。
- 异常处理比理想路径更重要，尤其是空 PDF、扫描件、缺 API Key、缺 Webhook 等演示时常见问题。
- 展示网站不仅要好看，还要讲清楚项目解决什么问题、如何工作、如何控制风险。
- 飞书推送让智能体结果进入协同流程，比单纯生成本地文件更符合课程要求。

## 8. 当前局限与未来改进

当前版本仍有局限：

1. 对扫描版 PDF 不能直接 OCR，需要用户先转换为可提取文本的 PDF。
2. 表格型财务数据的抽取受 PDF 质量和模型上下文限制，可能不完整。
3. 长招股说明书需要进行文本筛选，可能遗漏部分低频但重要信息。
4. 当前只支持单份招股说明书，不支持多公司对比、年报对比或多轮问答核验。
5. 飞书推送只发送摘要，不自动创建飞书文档或表格。

后续可以扩展：

- 接入 OCR，提高扫描版 PDF 支持能力。
- 增强表格识别和页码级证据引用。
- 增加多公司对比和多版本报告对比。
- 将输出同步到飞书文档或飞书表格。
- 增加人工标注反馈，用于改进 Prompt 和字段抽取质量。